

CIFRA AI

Preguntas Frecuentes del Producto

CFDI Intelligence, Forecasting & Reporting Architecture

1. Tecnologías utilizadas

¿Qué stack tecnológico usa CIFRA AI?

CIFRA AI está construido completamente sobre AWS y Python. El stack incluye: Amazon S3 (almacenamiento en capas Medallion), AWS Glue (ETL con PySpark), Amazon Athena (consultas SQL sobre Parquet), AWS Lambda (ingesta de CFDIs), API Gateway, Amazon SageMaker (entrenamiento del modelo de forecasting), ECS Fargate + ECR (despliegue del contenedor de la app), y Streamlit como framework de la interfaz de usuario.

¿Por qué se eligió la arquitectura Medallion (Bronze/Silver/Gold)?

La arquitectura Medallion es el estándar de la industria para pipelines de datos analíticos. Bronze almacena los XMLs originales sin modificar (fuente de verdad). Silver contiene los datos parseados, tipados y limpios en formato Parquet columnar. Gold almacena los agregados pre-calculados que alimentan el dashboard. Esta separación permite reproducibilidad, trazabilidad y eficiencia en costos de Athena.

¿Qué formato de archivo usa en cada capa?

Bronze: XML original (formato nativo del SAT). Silver y Gold: Apache Parquet con compresión Snappy. Parquet reduce el tamaño ~5x respecto al XML y permite a Athena leer solo las columnas necesarias, reduciendo significativamente el costo por query.

2. ¿Cómo se utiliza la solución?

¿Cómo accede el usuario a la aplicación?

CIFRA AI es una aplicación web desplegada en AWS ECS Fargate, accesible desde cualquier browser sin instalaciones. El

	usuario simplemente entra a la URL pública de la aplicación. No se requiere configuración adicional.
¿Cómo se suben los CFDIs?	Desde la página 'Subir CFDIs' de la app, el usuario selecciona uno o múltiples archivos XML de CFDI 4.0. La app valida automáticamente cada archivo (estructura, versión, RFC, UUID) y muestra una vista previa con los datos principales antes de enviarlos al pipeline.
¿Qué puede ver el usuario en el Dashboard?	El Dashboard muestra: total facturado histórico, número de CFDIs procesados, ticket promedio, último mes con variación porcentual, serie temporal de ingresos mensuales, top 10 clientes por facturación, composición por tipo de CFDI (Ingreso, Egreso, Traslado, Nómina, Pago) y distribución por método y forma de pago. Todos los datos son filtrables por año y exportables a CSV.
¿Qué muestra la página de Forecast?	La página de Forecast muestra las predicciones de ingresos, egresos e IVA para los próximos 3 meses, con una gráfica que conecta el histórico reciente (últimos 6 meses) con los puntos de forecast. La zona de predicción está sombreada para distinguirla visualmente del histórico.

3. ¿Cómo se adquieren y usan los datos?

¿De dónde provienen los datos?	Los datos son archivos XML de CFDI 4.0 emitidos por empresas mexicanas. Para el prototipo actual se utilizan CFDIs sintéticos de alta fidelidad (5,000 facturas) que respetan el XSD del SAT. En producción, los CFDIs se cargarían directamente desde el portal del SAT o desde los sistemas ERP de la empresa.
¿Cómo se procesan los XMLs?	Cada XML pasa por un parser personalizado (silver/parser.py) que extrae 25 campos del estándar CFDI 4.0: UUID, fecha de emisión, RFC emisor/receptor, totales, IVA, método de pago, tipo de comprobante, conceptos, y el timbre fiscal digital. Los datos tipados se almacenan en Parquet particionado por RFC, año y mes.

¿Cómo se garantiza la calidad de los datos?

CIFRA AI implementa validación en dos niveles: (1) al momento de la carga, el `validator.py` verifica la estructura XML, versión 4.0, RFC válido, UUID de 36 caracteres, al menos un concepto y campos obligatorios del SAT; (2) en la capa Silver, el schema Parquet garantiza tipos correctos para todos los campos numéricos y temporales.

4. Analítica e inteligencia aplicada

¿Qué tipo de analítica aplica CIFRA AI?

CIFRA AI combina tres niveles de analítica: (1) Descriptiva: dashboards con KPIs financieros históricos calculados con SQL sobre Athena; (2) Diagnóstica: segmentación por cliente, tipo de CFDI y método de pago para identificar patrones; (3) Predictiva: modelo de Machine Learning para forecasting de flujo de caja.

¿Qué modelo de ML se usa para el forecasting?

Se utiliza un modelo Random Forest Regressor (scikit-learn) entrenado con series temporales de 66 meses de facturación. El modelo usa como features lags de 1, 2 y 3 meses de ingresos, egresos, total facturado e IVA, más el mes del año como variable cíclica. Se entrena un modelo independiente para cada target (total, ingresos, egresos, IVA).

¿Cuál es el desempeño del modelo?

El modelo de forecasting de ingresos tiene un MAE de \$616,057 MXN y un RMSE de \$888,013 MXN, lo que representa aproximadamente un 17-19% del ingreso mensual promedio (~\$3.2M MXN). Para el IVA, el MAE es de \$98,726 MXN (~15% del promedio). El modelo de egresos tiene el mejor desempeño con un MAE de \$41,034 MXN.

¿Se usan LLMs o agentes de IA?

En la versión actual no. CIFRA AI se enfoca en modelos estadísticos y ML clásico para garantizar interpretabilidad y control sobre las predicciones financieras, que son críticas para la toma de decisiones empresariales. La integración de LLMs para consultas en lenguaje natural (Text-to-SQL sobre los datos) está considerada como una extensión futura.

5. Inputs y outputs del producto

¿Cuáles son los inputs del sistema?	El único input requerido del usuario son archivos XML de CFDI 4.0 emitidos por el SAT mexicano. Los XMLs deben cumplir con el XSD oficial del SAT para CFDI versión 4.0 y contar con timbre fiscal digital (UUID). No se requiere ningún otro tipo de configuración o dato adicional.
¿Cuáles son los outputs del sistema?	CIFRA AI produce cuatro tipos de outputs: (1) Dashboard interactivo con visualizaciones financieras en tiempo real; (2) Predicciones de ingresos, egresos e IVA para los próximos 3 meses en forma de gráficas y tabla; (3) Archivos CSV descargables con los datos de cada sección del dashboard; (4) Datos estructurados almacenados en S3 Gold (Parquet) disponibles para consumo por otras herramientas.
¿Cómo consume el usuario final los outputs?	Principalmente a través del browser: navega el dashboard para monitorear KPIs, consulta el forecast para planear el flujo de caja, y descarga CSVs para reportes o análisis adicionales en Excel. Los datos en Gold también pueden conectarse directamente a herramientas de BI como Power BI o Tableau mediante el conector de Athena.

6. Costo estimado a un año

¿Cuánto costaría operar CIFRA AI durante un año?	El costo estimado para una PyME con ~5,000 CFDIs/mes es de aproximadamente \$1,200 - \$1,800 USD/año en AWS, distribuidos así: S3 Storage ~\$5/mes, Glue Jobs ~\$10/mes (2 workers, 10 min/corrida diaria), Athena ~\$5/mes (<50GB escaneados), ECS Fargate (app) ~\$30/mes (0.5 vCPU, 1GB RAM), SageMaker (reentrenamiento mensual) ~\$5/mes. Total: ~\$55-70 USD/mes o ~\$660-840 USD/año. Con costos de desarrollo y mantenimiento estimados en \$500-600 USD/año, el costo total anual ronda los \$1,200-1,400 USD.
¿Qué factores incrementan el costo?	El principal driver de costo es el volumen de CFDIs procesados (afecta S3 y Glue) y la frecuencia de queries en Athena (afecta el costo por TB escaneado). Para empresas con más de 50,000 CFDIs/mes se recomienda evaluar el uso de AWS Glue Data Catalog con particionamiento más fino y la implementación de Result Caching en Athena para reducir costos.

